



西南财经大学  
SOUTHWESTERN UNIVERSITY OF FINANCE AND ECONOMICS

# 基于集成机器学习算法的 手机游戏用户未来消费金额预测 ——以游戏《野蛮时代》为例

研  
究  
报  
告

作者：张甜 钟鸿蔚 倪慈优 邱少娟 蒋楠

指导老师：李太勇 吴江

2019 年 6 月

## 摘要

基于当前各大平台的数据资源，人们将计算机技术用于数据挖掘和对目标的预测。运用多种机器学习算法，我们使用游戏玩家操作行为数据和消费记录数据来预测其未来消费意向和继续消费的金额，利用遗传算法（GA）对游戏玩家操作数据进行特征选择，以 20 个特征值为标准最终得到优化特征。之后，利用 TPOT 进行自动化机器学习，寻找最优模型对数据进行回归，并利用 19126 个玩家的游戏数据对最终的模型进行检验，并对比了未进行特征选择、随机选择、与消费相关特征选择的拟合效果。实验表明该思路构建的模型能同时兼顾良好的拟合效果和玩家特征的多样性。

**关键字：**遗传算法、自动化机器学习、特征选择、回归、游戏消费

# 目录

摘要 .....2

一、 引言 .....4

1.1 研究背景 .....4

1.2 研究现状 .....4

二、模型描述及理论基础 .....5

2.1 随机森林 .....5

2.2 XGBoost 算法 .....6

2.3 理论基础 .....6

三、 实验数据处理及分析 .....7

3.1 数据清洗 .....9

3.2 特征度量 .....9

3.2 名词概念 .....9

四、 实验算法设计 .....10

4.1 遗传算法 .....10

4.2 回归模型建立 .....11

4.3 评估指标 .....12

五、 实验及结果分析 .....12

5.1 实验过程 .....12

5.2 实验结果评估 .....13

六、 结束语 .....16

# 一、引言

## 1.1 研究背景

随着互联网在生活中的不断深入，网络游戏在人群中迅速发展，游戏消费也成了各个游戏玩家之间的常态。在以“王者荣耀”和“皇室战争”为代表的手机游戏市场内，海量用户生成数据被游戏运营平台记录存储。对这些数据进行分析，将有助于达到多方面的目的，例如评测玩家在游戏消费心理和付费意愿，游戏版本改进的用户反馈和游戏平衡性检测、用户黏度等等。基于其潜在的商业价值和应用前景，相关领域的研究也成为手游市场内外的热点。

## 1.2 研究现状

一些学者针对游戏用户消费因素进行了探究。张燕贞，喻承甫(2017)[1]采用标准量化表对青少年网络游戏成瘾的心里社会影响因素进行了研究，并发现专制教养、同伴侵害和非适应性认知等都对青少年网络游戏成瘾有关。温卢和张昊雯等(2018)[2]运用问卷调查和实证分析的方法探究影响网络游戏消费行为的因素，通过因子分析和回归分析，发现影响高校学生网络游戏消费行为的因素主要有娱乐社交、游戏产品创新、易用价值感知和营销方式等外部因素。黄云曼(2017)[3]

通过分析当前腾讯游戏的大数据精准营销，发现通过数据挖掘和聚类技术的用户画像搭建是可行的，包括用户的个性化需求和偏好。张鹏和庞涛等 (2017)[4]通过提出和设计利用非常有限的用户信息构建多个可用于及其学习的算法模型，将各个模型的预测结果进行融合输出的方法，快速甄别出一部分活跃度较高的潜在用户进行游戏产品的精准营销，从而提升游戏的产品下载率和使用率。一些学者针对用户消费数据进行了预测。李艳和代佳岳等(2012)[5]通过对 RTS 游戏（即时战略游戏）的对战记录进行分析，建立 5 种结构的神经网络模型来预测用户行为的方法，并发现基于单时间片输入的神经网络模型能够更快速地完成训练过程并达到满意的预测准确度。祝歆和刘潇蔓等(2017)[6]分别用 Logistics 回归、支持向量机以及这两种算法的融合构建了预测模型，并且

发现融合后的模型比单一模型能更好的预测网络购买行为。申一和周鹏

(2017)[7]针对大学生游戏消费行

为, 利用 CART 决策树对影响游戏消费行为的复杂因素进行回归分类及规则提取, 从众多的数据中得出一致性规律, 也验证了 CART 决策树方法良好地预测了影响大学生消费行为的因素。

上述文献一方面证明了游戏上瘾和消费与外界因素如社交媒体, 游戏本身因素如营销策略、产品创新等相关。另一方面也证明了我们可以通过用户之前的消费行为记录来进行其未来消费态度和金额的预测。但针对游戏玩家局内表现的数据(包括注册时间、在线时长、对战结果, 支付记录等)来预测未来支付行为的文献则相对较少。

本文获取了由游戏运营商发布的 2018 年 3 月与 4 月的玩家操作数据, 对该游戏进行了针对性的分析和数据特征处理, 综合多种模型并比对各模型的表现, 直接分析了该游戏当前运营状况和预测了游戏盈利前景。

本文的余下部分安排如下: 第二部分分析算法理论基础与应用原理; 第三部分是数据处理和分析部分; 第四部分进行实验结果分析; 最后一部分提出全文结论。

## 二、模型描述及理论基础

### 2.1 随机森林

随机森林算法具有较高的的预测准确率, 不容易出现过拟合, 效率也优于很多其他算法。方匡南和吴见彬等(2010)通过对信通卡信用风险的研究发现, 随机森林方法的预测准确度明显高于基准的 SVM 模型和 Logistic 模型, 而且没有出现过度拟合的现象。向尚和邹凯等(2016)在构建智慧城市信息安全风险预测模型中发现, 随机森林算法由于需要调整的参数和耗时少, 在预测精度相近的结果下, 随机森林算法的效率高于 SVM 和朴素贝叶斯。武华和匡海波等(2018)在通过随机森林回归模型实现对 BDI 指数的预测中表明, 随机森林回归算法可以直接体现变量间的交互关系, 直观地给出影响因素作用机理的量化体现, 并且可以得到比较精确的预测结果。董倩和孙娜娜等(2014)在基于网络搜

索数据进行房地产价格预测时表明，随机森林对于数据可以产生高准确度的分类器和处理大量的输入变量；在决定类别时，评估出变量的重要性，而且在建造森林时可以在内部对于一般化后的误差产生不偏差的估计；最终，随机森林能够得出较为准确的预测值。

## 2.2 XGBoost 算法

XGBoost 算法相较于传统的数据挖掘算法，具有运算速度快、准确度高、预测精确度高、可扩展的优势。蒋晋文和刘伟光(2017)运用 XGBoost 算法准确预测了制造业产品质量。叶倩怡和饶泓(2017)采用 XGBoost 方法对公司销售额进行预测，并发现该算法无论是训练速度还是在 RMSPE 评价标准上都具有明显优势。王重仁和韩冬梅(2017)使用 XGBoost 算法来进行客户流失预测，并发现社交网络分析和 XGBoost 相结合的客户流失预测方法优于传统方法。张昊和纪宏超(2017)将 XGBoost 算法应用于商品推荐中，准确预测了用户购买行为。黄卿和谢合亮(2018)在对股指期货下 1 分钟价格的变动方向的预测研究中发现，XGBoost 的预测能力要优于传统的神经网络和支持向量机。

## 2.3 理论基础

### (1) 决策树 (Decision Tree)

决策树是一种基本的分类与回归方法，可视作一种 if-then 规则集合。决策树由节点和有向边组成，内部节点代表了特征属性，外部节点（叶子节点）代表了类别，决策树的学习利用已经有的数据学习各种规则对未来未知的数据进行预测。决策树分为两大类：回归树和分类树，前者用于预测实数值，后者用于分类标签值。




图 2.3 决策树结构



## (2) 梯度提升 (Gradient Boosting)

梯度提升算法以弱预测模型（通常是决策树）的集合的形式产生预测模型，它利用最速下降的近似方法，即利用损失函数的负梯度在当前模型的值，作为回归问题中提升树算法的残差的近似值（伪残差），拟合一个回归树。

Gradient Boosting 的算法流程为：

1. 初始化:  $f_0(x) = \arg \min_{\gamma} \sum_{i=1}^N L(y_i, \gamma)$

2. 对  $m=1$  到  $M$

$$F_0(x) = \arg \min_{\rho} \sum_{i=1}^N L(y_i, \rho)$$

(a) 计算负梯度:

$$\tilde{y}_i = -\frac{\partial L(y_i, f_{m-1}(x_i))}{\partial f_{m-1}(x_i)}, i = 1, 2 \dots N$$

(b) 通过最小化平方误差，用基学习器  $h_m(x)$  拟合  $\tilde{y}_i$ ,

$$w_m = \arg \min_w \sum_{i=1}^N [\tilde{y}_i - h_m(x_i; w)]^2$$

(c) 确定步长  $\rho_m$ ，以使  $L$  最小，

$$\rho_m = \arg \min_{\rho} \sum_{i=1}^N L(y_i, f_{m-1}(x_i) + \rho h_m(x_i; w_m))$$

(d)  $f_m(x) = f_{m-1}(x) + \rho_m h_m(x; w_m)$

3. 输出  $f_M(x)$

## 三、实验数据处理及分析

我们的数据来源于 DC 竞赛平台中《野蛮时代》游戏的用户数据，共 100 万条，特征 109 个。该数据集中不仅有玩家登陆时间、在线时长、消费金额等

数据，还有每局游戏中角色等级工具等数据，覆盖面全面且数据量大，有益于我们本次课题的研究。

本文针对课题研究的目标，设计了基于遗传算法的特征挑选算法，其流程如下：

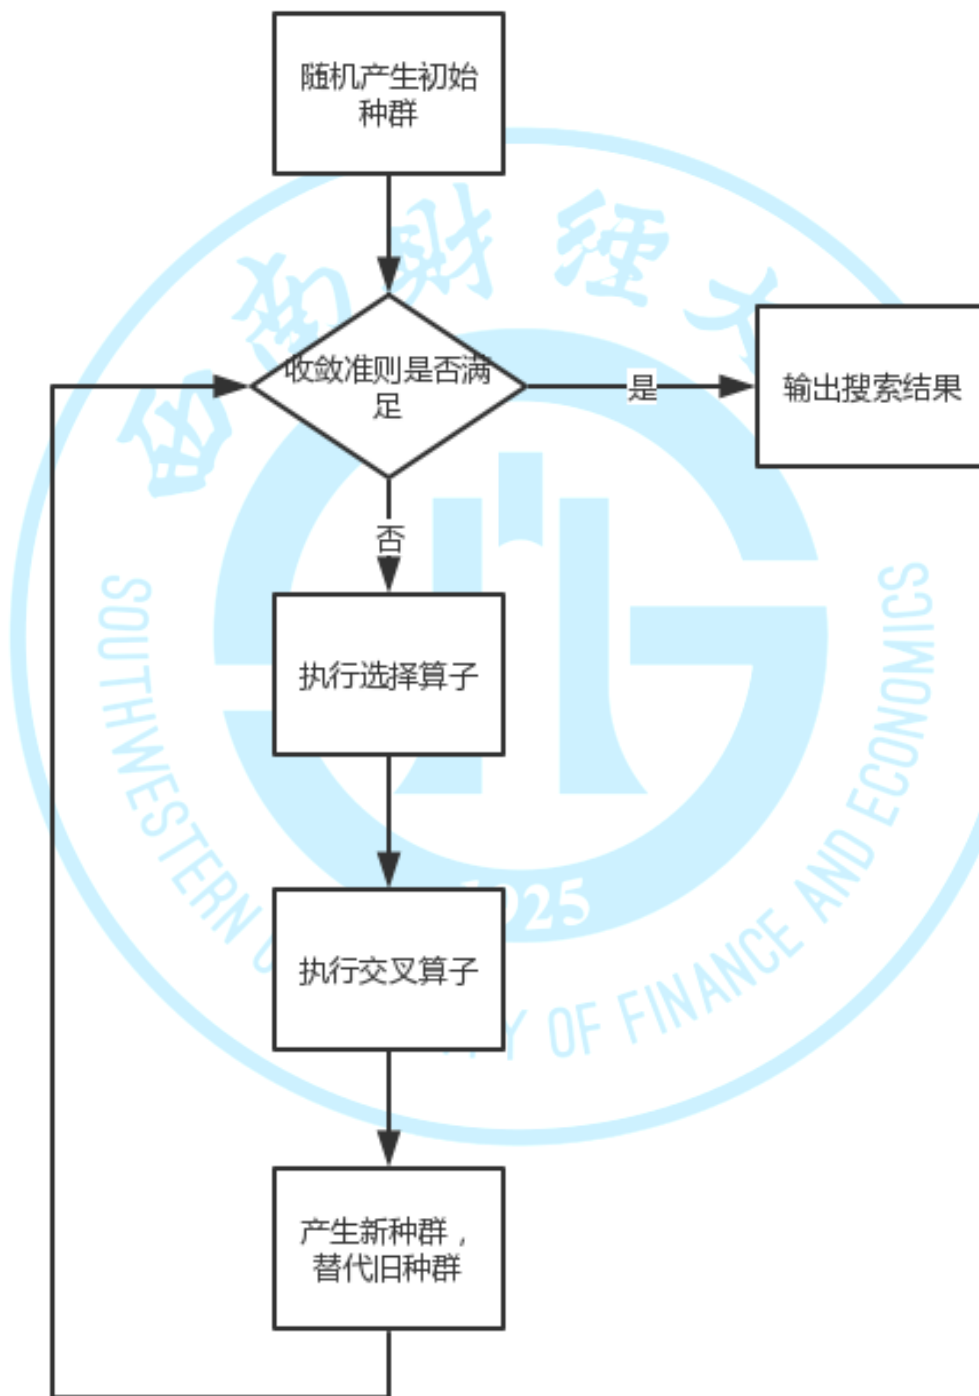


图 3



### 3.1 数据清洗

通过分析数据分布，并结合试玩体验，我们发现进入游戏后的入门教程环节不会发生收费项目。另外通过对数据的探查，我们发现最终付费的玩家很少，那些从始至终总并未付款的玩家数据对我们本次课题的研究可以视为噪声。因此我们筛去了前七天没有付款的玩家，最终将原本 100 多万条的数据压缩为 19126 条。

### 3.2 特征度量

本课题的研究中，希望可以借此分析出与玩家付费有关的行为特征，因此在这里对于 109 个特征，本文最终决定采用遗传算法的思想，利用遗传算法适者生存的核心思想，对特征进行筛选，以此最终挑选出对回归目标强相关的特征。

### 3.2 名词概念

#### 3.2.1 染色体

由从所有特征中选择出来特征构成，内容为特征对应的编号。由于实验中一个个体对应一个染色体，因此也用个体表示染色体

$$DNA = \langle F1, F2, F3, F4, F5, F6, F7, F8, F9, F10 \rangle$$

#### 3.2.2 种群

一个种群由多个个体构成，其中每个个体由自身的染色体进行表示。在本文中，每一代进行进化之后，将会代替原来的种群

如一个有六个个体的种群 F1:

$$F1 = \langle C1, C2, C3, C4, C5, C6 \rangle$$

#### 3.2.2 亲代

在进行种群进化时，需要从原有的种群中选择两个个体提供染色体进行遗传进化，这其中经过一定概率选择出来的两个个体就被成为亲代，每一对亲代对应产生两个子代。

## 四、实验算法设计

### 4.1 遗传算法

#### 4.1.1 个体适应度

如何判定当前个体的生存适应度，关键在于对个体回归预测的评价。由于数据中特征数量较多，难以确定某种具体的回归模型用于评测个体生存适应度，因此我们最终采用多个模型校正决定系数的累加来表示一个个体的生存适应度。最终在选定的模型中，有：线性回归、决策树回归、SVR、KNN 回归、随机森林回归、ADA 回归和 GBR 回归这七种模型综合评判。

#### 4.1.2 个体选择

本文采用轮盘赌选择法对个体进行选择，轮盘建立依据每个个体的生存适应度，以个体 C1、C2、C3、C4 为例：

个体	生存适应度	被选择几率
C1	28	28.9%
C2	23	23.7%
C3	12	12.4%
C4	34	35.1%

表 4.1.2

通过该方法，生存适应度高的个体将有更大几率留下来。以此在每一次进化的种群中进行挑选，可以在每一轮中获得一个更适应环境的亲本。

#### 4.1.3 单点交叉

根据 GA 算法的定义，在获得两个亲本之后，接下来需要进行染色体的交叉。以个体 C1 中染色体和 C2 中染色体为例，在进行单点交叉时，需要随机选择染色体中一点，然后将交叉点前后的染色体部分进行染色体之间的交叉对调，以此产生后代。

如图，左边两个亲代进行随机选择，以第四点作为染色体交叉点，得到右侧两个子代。




图 4.1.3

## 4.2 回归模型建立

进行完相应的特征选择之后，需要选择合适的模型对数据进行回归预测。为了得到更好的回归效果，最好的方法是对所有的回归模型都进行尝试。本文在这里采用了 TPOT 库协助进行建模。TPOT 是一种基于遗传算法优化机器学习管道(pipeline)的 python 自动机器学习工具，可以智能地搜索数千个可能的 pipeline，为数据集找到最好的 pipeline。它可以搜索并进行特征选择、模型选择、参数调节等非常重要的部分：

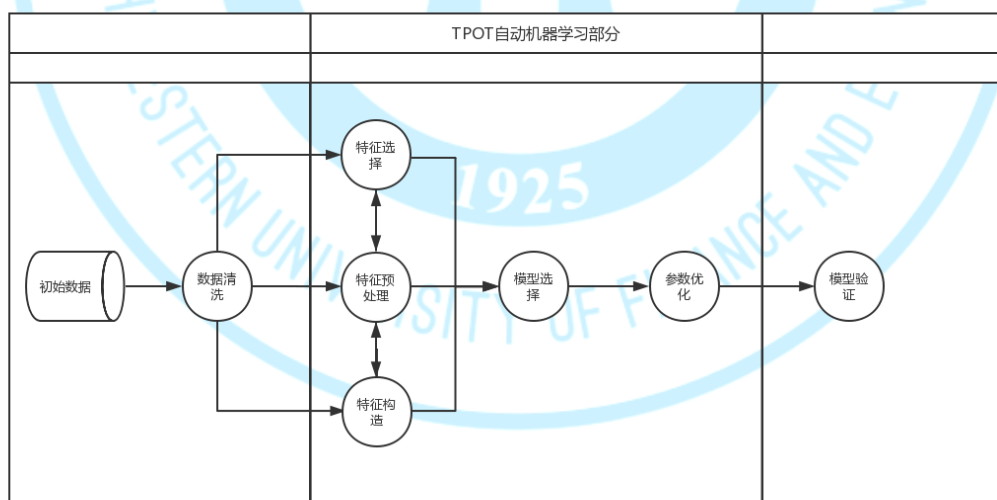


图 4.2

针对回归模型，TPOT 目前支持的回归器主要有决策树、集成回归树、线性模型和 xgboost。TPOT 会对输入的数据做进一步处理操作，包括二值化、聚类降维、基于方差、基于 F-值的百分比等。根据模型效果，TPOT 则会对输入特

征做特征选择操作，包括基于树模型、基于方差、基于 F-值百分比，不过即使如此，在使用 TPOT 进行建模之前仍需要对数据进行必要的清洗工作。

### 4.3 评估指标

常用的回归指标有均方误差（MSE）、均方根误差（RMSE）、平均绝对值误差

（MAE）、R<sup>2</sup> 决定系数和校正决定系数。针对本课题研究，本文在计算所有评估指标的同时，着重考虑均方根误差和校正决定系数两个指标。

#### 4.3.1 均方根误差（RMSE）

$$MAE = \frac{1}{m} \sum_{i=1}^m |(y_i - \hat{y}_i)|$$

由于本课题是针对游戏玩家消费金额的回归预测，因此采用均方误差并不准确，因此需要采用平均绝对值误差，以衡量回归指标和有效性。

#### 4.3.2 校正决定系数

$$R^2_{\text{adjusted}} = 1 - \frac{(1 - R^2)(n - 1)}{n - p - 1}$$

其中 R<sup>2</sup> 为 R-square 决定系数、n 为样本数量，p 为特征数量。由于数据集的体积越大，R<sup>2</sup> 越大，因此针对不同的数据集会有差异，所以本文另外同时选择校正决定系数对回归结果进行评估。

## 五、实验及结果分析

### 5.1 实验过程

#### 5.1.1 实验环境

一台基于 Windows10 操作系统的华硕 FL5900U 笔记本电脑，四核 A8 处理器，4GB 内存，512G 机械硬盘。算法实现采用 python 编程语言对整个实验进行实现。

#### 5.1.1 实验过程

我们的模型采用 Python 语言编写，利用了名为 scikiti-learn 的 python 机器学习库、TPOT 自动化机器学习库。通过遗传算法对原清洗过的数据进行特征提取，并得到一个初始的种群。然后利用算法对总群进行迭代，最终得到优化后的特征选择。将优化后的特征选择数据集放入 TPOT 中进行建模，最终根据每一个个体输出的模型进行回归预测并对比，找出该种群中最佳的特征选择和对应的模型，具体流程图如下：

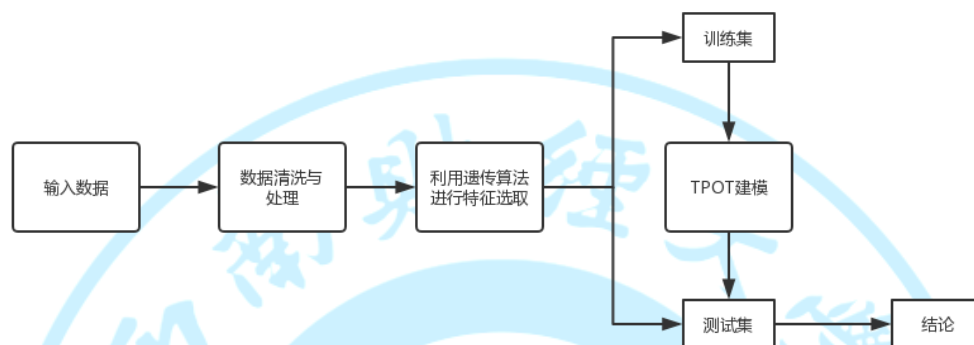


图 5.1.1

## 5.2 实验结果评估

本文首先利用遗传算法对特征进行选择，其中种群中个体数量为 15 个，个体染色体长度为 30，迭代次数为 10 代。在最终迭代次数达到目标要求之后，输出最终进化后的 15 个体，并分别放入 TPOT 进行模型建立。为了解决 TPOT 在数据量巨大的情况下运行缓慢的问题，本文从 19126 条数据中随机抽取了 500 条，放入 TPOT 模型中进行建模，其中种群数量为 20，迭代次数为 100 代。

由于针对不同的个体，TPOT 产生的模型和参数会有差异，因此对于得到的不同模型，需要利用相应的特征选择进行模型验证。在验证时采用全部的 19126 条数据，其中 0.75 为训练集、0.25 为测试集。

经过所有个体模型表现的对比，最终得到种群中第 8 个个体对应的回归效果最好，且对应的模型主要为随机森林。以下是第八个个体中的特征和释义，由于在遗传算法的特征挑选中，强相关的特征会以大概率多次被选择，因此会出现同一个特征出现多次的情况。在改个体中有两个特征重复出现了两次，这里仅显示不重复的 18 个特征：

序号	变量名	字段解释
1	bd_warehouse_level	建筑：仓库等级
2	sr_gathering_hunter_buff_level	科研：领土采集奖励
3	pay_price	付费金额
4	ivory_add_value	象牙获取数量
5	pve_lanch_count	主动发起 PVE 次数
6	training_acceleration_reduce_value	训练加速使用数量
7	sr_troop_load_level	科研：部队负重
8	infantry_add_value	勇士招募数量
9	bd_dolmen_level	建筑：智慧神庙等级
10	magic_add_value	魔法获取数量
12	sr_infantry_tier_4_level	科研：狂战士
13	bd_guest_cavern_level	建筑：联盟大厅等级
14	sr_shaman_tier_2_level	科研：吟唱者
15	bd_watchtower_level	建筑：瞭望塔等级
16	sr_hide_storage_level	科研：资源保护
17	bd_magic_coin_tree_level	建筑：魔法幸运树等级
18	pve_battle_count	PVE 次数

表 5.2-1

根据上述筛选出来的特征，我们可以看出，相对于在游戏中表现比较激进的游戏玩家，会更容易出现在游戏中消费的现象。从另外一个角度也能表明，玩家在游戏游戏中的游戏表现特征，也可以为最终游戏消费金额的预测提供有利信息。

为了对比经过遗传算法挑选特征前后的拟合效果，本文将实验结果随机特征挑选的回归分析做了对比，下表中给出了筛选后和筛选前的拟合评估情况：

评估指标	挑选过后的特征	随机特征
均方误差(MSE)	163082.0557	206229.0187
均方根误差(RMSE)	403.8341	454.1244



平均绝对值误差(MAE)	73.6148	76.4068
R2 决定系数	0.6402	0.2216
校正决定系数	0.6399	0.2208

表 5.2-2

其中平均绝对值误差达到 73（美元），在针对整体游戏金额的回归预测中，这样的值效果还是尚佳的。另外校正决定系数为 0.64，事实证明，这样回归分析适合对整体的游戏消费金额的预测，而数据中由于游戏玩家众多，玩家相互之间差异巨大，因此并不适合利用本数据进行回归分析。相对于未进行特征筛选时校正决定系数的 0.22，筛选后的 0.64 已经有了很大的提升。

另外，为了对比特征筛选的必要性，本文将通过遗传算法筛选后的特征进行的回归预测与所有特征进行和回归预测、仅与游戏消费直接相关的特征回归预测进行了对比：

评估指标	挑选过后的特征	所有特征	与消费直接相关的特征
均方误差(MSE)	163082.0557	255342.2399	224175.6727
均方根误差(RMSE)	403.8341	505.3140	473.4719
平均绝对值误差(MAE)	73.6148	99.1500	74.5806
R2 决定系数	0.6402	0.4689	0.3710
校正决定系数	0.6399	0.468	0.3703

表 5.2-3

通过上表对比，可以看出。如果采用所有特征对最终游戏玩家未来的消费金额进行预测，出现了平均绝对值误差过高的现象，可以得知对于金额的预测在所有的 109 个特征中出现了噪声特征，但是其校正决定系数较好，说明如果采用所有的特征能够体现不同玩家个人的特点；在仅选择与游戏消费有关的特征回归预测中，其平均绝对值误差表现较好，值为 473.47，但是在校正决定系数中则仅有 0.37，表现较差。这说明这些特征对于预测整体游戏玩家消费金额是有利的，但是却难以针对每个个体的特点进行更加精准的预测。

## 六、 结束语

随着智能手机的普及和手游的低龄化，对游戏玩家的消费特性也成了逐渐被

高度重视的问题，如何通过分析一个玩家的行为特征来判断其对游戏的成瘾程度和消费意向，无论对游戏公司，还是对高校、家长都有着重要的意义。本文从对游戏玩家的游戏表现特征分析出发在 19126 名游戏玩家中随机抽 500 个玩家数据，通过遗传算法对 109 个特征中进行重要性特征筛选，以 20 个特征值为提取标准。最后将这些特征下的所有数据放入 TPOT 进行建模，并最终得到了较好的效果。本文的贡献在于：一、采用了遗传算法对特征进行挑选。由于遗传算法有很好的优化效果，因此挑选出来的特征都是与回归目标强相关的。二、在数据降维中保留了原数据，利于研究者对结果进行分析和解读。由于在通常的降维方法中，一般采用 PCA 降维，会破坏原来的特征而导致无法解读。而本文的方法由于保留了原数据的特征，因此能够做到对游戏玩家的特点进行分析，为相关的分析提供了非常好的思路。

但是，本文还存在部分问题和一些局限性。首先就是在生成初始种群的时候，由于是随机挑选的特征，因此会影响到最终得到的优化结果，这也意味着一次实验中的优化结果并不是真正的最优结果，因此需要大量的实验次数去反复尝试。同时在遗传算法中，不仅有单点交叉，还有多点交叉和变异操作，本文并没有采用。另外，特征挑选是个体适应度中，本文仅采取了每个回归模型中校正决定系数累加的方式进行评估。这是一个关键的部分，由于不同的测量方式也会影响到最终的优化选择，因此这里也需要不断去尝试。所以，如果为了实际应用与对游戏玩家的特征分析和消费金额预测，仍需要继续调整模型，并不断提高回归效果与实用性。

### 参考文献：

- [1]丁志东. 长尾信息的个性化推荐中的特征选择优化算法[D].北京交通大学,2016.
- [2]杨剑锋,乔佩蕊,李永梅,王宁.机器学习分类问题及算法研究综述[J].统计与决策,2019,35(06):36-40.
- [3]覃梦秋. 基于情境感知的移动终端用户消费行为预测研究[D].重庆大学,2015.
- [4]王伟华. 基于模型融合的平台虚假用户识别研究[D].广东工业大学,2018.

- [5]张文杰,蒋烈辉.一种基于遗传算法优化的大数据特征选择方法[J/OL].计算机应用研究:1-5[2019-06-09].<https://doi.org/10.19734/j.issn.1001-3695.2018.05.0495>.
- [6]辛宇,童孟军,华宇婷.一种基于最优特征选择改进的遗传算法[J].传感技术学报,2018,31(11):1747-1752.
- [7]李静.基于改进遗传算法的数据特征分类[J].现代电子技术,2018,41(14):166-169.
- [8]富坤,富成科,汪友华,杨晓光.基于支持向量机对种群特征回归分析的自适应遗传算法[J].南昌大学学报(理科版),2007(04):391-395.
- [9]牛晓青,叶庆卫,周宇,王晓东.基于遗传算法特征选择的自回归模型脑电信号识别[J].计算机工程,2016,42(03):283-288+294.
- [10]宋涛,王星.基于二次聚类和隐马尔可夫链的持卡消费行为预测[J].计算机应用,2016,36(07):1904-1908.
- [11]樊志文.顾客消费行为预测——基于 RFM 与灰色 GM(1,1)模型的研究[J].经营与管理,2015(02):128-131.
- [12] Julia Bronnmann, Frank Asche. Sustainable Seafood From Aquaculture and Wild Fisheries: Insights From a Discrete Choice Experiment in Germany[J]. Ecological Economics, 2017, 142.
- [13] Sepehr Ghader, Carlos Carrion, Lei Zhang. Autoregressive continuous logit: Formulation and application to time-of-day choice modeling[J]. Transportation Research Part B, 2019, 123.
- [14] Ruggiero Lovreglio, Achille Fonzone, Luigi dell'Olio. A mixed logit model for predicting exit choice during building evacuations[J]. Transportation Research Part A, 2016, 92.
- [15] Ann Shortridge, Brigitte Steinheider, Denise G. Bender, Vivian E. Hoffmeister, Carrie A. Ciro, Heather M. Ross, Ken Randall, Gary Loving. Teaching and evaluating interprofessional teamwork using sequenced instruction and TeamSTEPPS™ Team Performance Observation Tool (TPOT)[J]. Journal of Interprofessional Education & Practice, 2019.
- [16] Wenqiang Zhang. Radar Signal Recognition Based on TPOT and LIME[A]. 中国自动化学会控制理论专业委员会.第 37 届中国控制会议论文集 (C) [C].中国自动化学会控制理论专业委员会:中国自动化学会控制理论专业委员会,2018:6.
- [17] K. Ahmed, N. Khan, D. Anderson, J. Watkiss, B. Challacombe, M.S. Khan, P. Dasgupta, D. Cahill. 63 Introducing The Productive Operating Theatre (TPOT) programme in urology theatre suites[J]. European Urology Supplements, 2012, 11(1).